

Propuesta de Proyecto de Business Intelligence

Sistema de recomendación musical basado en similitud multifactorial
Dataset: 490K Spotify Song Audio Embeddings & Metadata (Kaggle)

1. Descripción del proyecto

Se propone desarrollar un sistema de información de Business Intelligence que, a partir de una canción ingresada por el usuario (o un conjunto de canciones que definen su perfil de gusto), prediga y recomiende las siguientes canciones más afines dentro de un catálogo de aproximadamente 491.000 canciones de Spotify. La predicción combina de forma ponderada varios factores: el perfil acústico de la canción (cómo suena), el estado de ánimo o *mood* que transmite, el género musical del artista y su popularidad. El sistema entrega además un reporte visual (dashboard) que explica por qué se recomendó cada canción, aportando transparencia y valor analítico al resultado.

2. Diccionario de datos del dataset

2.1. Archivo songs.csv (~491.632 registros)

Campo	Tipo	Descripción
id	Texto	Identificador único de la canción en Spotify.
name	Texto	Título de la canción.
album_name	Texto	Nombre del álbum al que pertenece la canción.
artists	Lista de texto	Lista de nombres de los artistas que interpretan la canción.
danceability	Numérico [0–1]	Qué tan adecuada es la pista para bailar (ritmo, estabilidad del tempo, regularidad del beat).
energy	Numérico [0–1]	Medida perceptual de intensidad y actividad de la pista.
key	Entero [0–11]	Tonalidad de la pista (0 = Do, 1 = Do#, ... 11 = Si).
loudness	Numérico (dB)	Volumen general de la pista en decibelios (aprox. –42,5 a 0).
mode	Binario {0,1}	Modalidad: 1 = modo mayor (sonoridad alegre), 0 = modo menor (sonoridad melancólica).
speechiness	Numérico [0–1]	Presencia de palabras habladas en la pista (valores altos = rap, podcast, poesía).

Nota: el dataset incluye además archivos de embeddings de audio (VGGish, MERT, PANNs, Mel Spectrogram) y letras de canciones, que se consideran fuera del alcance inicial pero podrían incorporarse como mejora futura de la similitud acústica.

2.2. Archivo artists.csv (~63.857 registros)

Campo	Tipo	Descripción
id	Texto	Identificador único del artista en Spotify.
name	Texto	Nombre del artista en Spotify.
followers	Entero	Número total de seguidores en Spotify (0 a ~168 millones).

Campo	Tipo	Descripción
popularity	Entero [0–100]	Puntaje de popularidad del artista calculado por Spotify.
genres	Lista de texto	Todos los géneros asociados al artista (ej. ['indie folk', 'folk punk']). Puede estar vacía.
main_genre	Texto (categoría)	Género principal del artista: Electronic, Rock, Pop, Hip-Hop, Folk, Classical, etc.

3. Generación de los datos derivados (mood, género, popularidad)

Es importante aclarar que **ningún dato se mapea manualmente**: los tres factores derivados se generan de forma automática y masiva para las ~491.000 canciones durante el proceso ETL, mediante operaciones vectorizadas en Python (pandas/NumPy) y consultas SQL. El procedimiento es el siguiente:

3.1. Cruce canción–artista (JOIN automático)

El campo *artists* de *songs.csv* contiene los nombres de los artistas, y *artists.csv* contiene esos mismos nombres con su género y popularidad. En el ETL se toma el **artista principal** (primer elemento de la lista) de cada canción y se realiza un JOIN por nombre contra *artists.csv*. Esta única operación enriquece automáticamente todas las canciones con *main_genre*, *genres*, *popularity* y *followers* de su artista. Las canciones cuyo artista no encuentre coincidencia (casos residuales por diferencias de escritura) se marcan con género "Desconocido" y popularidad media, y se cuantifican en el informe como parte de la limpieza de datos.

3.2. Mood: campo calculado con fórmula

El mood no existe en el dataset; se **calcula** para cada canción a partir de tres campos que sí existen: *energy*, *danceability* y *mode*. Se define un puntaje de ánimo:

$$\text{Mood}(c) = 0,5 \cdot \text{energy} + 0,3 \cdot \text{danceability} + 0,2 \cdot \text{mode}$$

Este valor continuo [0–1] permite además clasificar cada canción en cuatro cuadrantes interpretables para el dashboard: **Enérgico/Festivo** (energía y bailabilidad altas, modo mayor), **Intenso/Agresivo** (energía alta, modo menor), **Relajado/Alegre** (energía baja, modo mayor) y **Melancólico** (energía baja, modo menor). El cálculo se ejecuta una sola vez sobre toda la tabla (una línea de pandas vectorizada) y el resultado se almacena como columna nueva en la base de datos.

3.3. Coincidencia de género: se evalúa al momento de la consulta

No requiere generar ningún dato nuevo: gracias al JOIN del paso 3.1, cada canción ya tiene el *main_genre* y la lista *genres* de su artista. Cuando el usuario consulta una canción *q*, el sistema compara en tiempo real: 1,0 si la candidata comparte el género principal; 0,5 si comparte al menos un subgénero de la lista; 0,0 en caso contrario. Es una comparación de campos, no un mapeo manual.

3.4. Popularidad: normalización de un campo existente

El campo *popularity* [0–100] ya viene calculado por Spotify en *artists.csv*. Solo se normaliza dividiendo entre 100 para llevarlo al rango [0–1] de la fórmula: $\text{Pop}(c) = \text{popularity}/100$. Igualmente se hace en una sola operación para todo el catálogo.

4. Fórmula de predicción

El motor de recomendación utiliza un modelo de **filtrado basado en contenido**. Para una canción de consulta q , cada canción candidata c del catálogo recibe un puntaje:

$$\text{Score}(c) = w_1 \cdot \text{Sim}_{\text{audio}}(c, q) + w_2 \cdot \text{Sim}_{\text{mood}}(c, q) + w_3 \cdot \text{Género}(c, q) + w_4 \cdot \text{Pop}(c)$$

a) Similitud acústica ($w_1 \approx 0,45$): similitud del coseno, $\cos(\theta) = (A \cdot B) / (||A|| \cdot ||B||)$, entre los vectores normalizados [danceability, energy, loudness, speechiness] de ambas canciones. **b) Similitud de mood ($w_2 \approx 0,25$):** $\text{Sim}_{\text{mood}} = 1 - |\text{Mood}(c) - \text{Mood}(q)|$, usando el campo calculado en 3.2. **c) Género ($w_3 \approx 0,20$):** coincidencia descrita en 3.3. **d) Popularidad ($w_4 \approx 0,10$):** valor normalizado de 3.4; el sistema incluirá un modo "descubrimiento" que invierte este factor ($1 - \text{Pop}$) para sugerir canciones menos conocidas.

El sistema ordena el catálogo por Score y devuelve el **Top 10**. Si el usuario ingresa varias canciones, sus vectores se promedian para construir un "vector de gusto" que simula un perfil de escucha. Los pesos $w_1 \dots w_4$ se calibrarán experimentalmente y su ajuste se documentará en la sección de resultados del informe.

5. Arquitectura del sistema de información

(1) ETL: script en Python que descarga los CSV de Kaggle, limpia duplicados y nulos, normaliza atributos, ejecuta el JOIN canción–artista y calcula el campo mood. **(2) Base de datos:** PostgreSQL (o SQLite) con tablas *canciones*, *artistas*, *generos* y *recomendaciones*, con modelo entidad–relación documentado. **(3) Motor de predicción:** Python con pandas, NumPy y scikit-learn para el cálculo vectorizado de similitudes. **(4) Interfaz y reporte BI:** aplicación web con Streamlit donde el usuario busca una canción y obtiene el Top 10 recomendado, junto con gráficas: distribución de géneros, mapa de moods (energía vs. bailabilidad) y desglose visual de los factores que explican cada recomendación.

6. Validación

El sistema será probado por **10 usuarios**. Cada uno ingresará 2–3 canciones que conozca, revisará las recomendaciones y completará el cuestionario **SUS** (System Usability Scale, 10 ítems en escala Likert). Se reportará el puntaje SUS promedio (0–100), considerando 68 como umbral de usabilidad aceptable según la literatura. Complementariamente, cada usuario calificará de 1 a 5 la relevancia percibida de las recomendaciones, obteniendo una métrica de precisión del modelo.

7. Entregables

(a) Base de datos poblada con ~490.000 registros enriquecidos; (b) aplicación funcional de recomendación con dashboard BI; (c) informe en formato IEEE de máximo 6 páginas con metodología, fórmula de predicción, resultados, gráficas y validación SUS con los 10 usuarios.